Introducción

Nota: En este documento describo de forma general cómo he ideado las listas de palabras para que sean fácilmente utilizables por nuestro sistema. En caso de que nuestro sistema no acepte el tratamiento de ciertas formas tendríamos que evaluar si cambiar la forma de etiquetar las entradas del JSON o cambiar el funcionamiento del sistema. Dicho esto:
Hay 3 archivos principalmente:

- lexico_general.json: Contiene una recopilación de todas las formas no verbales que son diferentes en catalán y valenciano. Todas las formas ambiguas están anotadas con su correspondiente problema.
- verbos_diferentes_conjugados.json: Contiene una recopilación de todos aquellos verbos que son diferentes en catalán y valenciano, así como todas sus conjugaciones. De haber formas ambiguas, están también correctamente anotadas.
- conjugaciones_general.json: Contiene una recopilación de todos los verbos de apertium cuya forma no es diferente en catalán y valenciano pero sí algunas de sus conjugaciones.

Tratamiento de cada archivo

lexico_general.json

Expresiones multipalabra: El archivo está ordenado de manera que aparecen las entradas ordenadas de mayor a menor longitud de palabras. Es decir, las entradas con más palabras aparecen primero. La idea detrás de esto es que el sistema compruebe si aparecen exactamente todas las palabras de una cierta expresión multipalabra, y en dicho caso, que la sustituya. En caso de que no sea una coincidencia exacta no debe sustituirlo. Existen varias maneras de abordar esto, en función de cómo esté previsto que funcione el sistema. Quizá la más sencilla sea que, dada una palabra de una frase a traducir, se compruebe si esa misma funciona como subconjunto de una de estas expresiones multipalabra. De ser así, se pasa a comprobar la siguiente palabra de la frase y de la expresión. En caso de que no se detecte una coincidencia, se aborta la comprobación y se pasa a la siguiente expresión. Un ejemplo para clarificar esta idea:
Dada la frase “Va sortir de cop i volta.”
Y la expresión del diccionario:

```
{
  "espanol": "de golpe y porrazo",
  "catalan": "de cop i volta",
  "valenciano": "de sobte",
  "tipo": "v:lexic_val_PENDENT",
  "fuente": "unificado",
  "id": "E0041",
  "categoria": "adv"
},
```

1. Se traducirían las dos primeras palabras “Va eixir
2. Al llegar al “de” debería mirar en la lista si hay expresiones multipalabra que empiecen por “de”.
3. En caso de que sí, se pasará a mirar la siguiente palabra, “cop”. Se descartarán las expresiones que empiecen por “de” y no continúen por “cop”.
4. Se continuarán comprobando las palabras de la frase y las expresiones hasta encontrar una coincidencia exacta o por el contrario, no encontrar ninguna. En el primer caso, se continuaría la traducción a partir de la siguiente palabra de la frase no perteneciente a la expresión. En el segundo caso, se pasaría a mirar si la palabra “de” aparece en la lista sin expresión. A partir de ahí, se continuaría haciendo la traducción de forma habitual.

Caso 1 ambigüedad: Colisión
Este caso se produce cuando una palabra de la lista se puede decir de diferentes maneras en catalán o valenciano. Por ejemplo, “batlle” (forma catalana) se puede decir como “batle” o “alcalde” en valenciano, siendo “alcalde” la forma preferida por la AVL.

Estos casos son detectables porque las entradas están marcadas con los siguientes campos:

```
"canonica": true,
"lado": "val",
"problema": "colision",
"id_colision": "E1468"
```

El campo “problema” identifica que se trata de un problema de colisión.
El campo “id_colision” identifica con qué otra entrada del diccionario se genera la colisión.
El campo “lado” indica si este problema se da al traducir del catalán al valenciano (en cuyo caso, estará marcado como “val”) o del valenciano al catalán (etiqueta “cat”).
El campo “canonica” sirve para identificar la forma preferida. Se debe priorizar la forma que tenga la etiqueta “canonica” en “true”.

Caso 2 ambigüedad: Homonimia
Este caso se produce cuando una palabra se debe traducir cuando pertenece a una cierta categoría gramatical pero no cuando pertenezca a otra. Se caracteriza por los siguientes campos:

```
"categoria": "n",
"forma_problematica": "bes",
"lado": "cat",
"problema": "homonimia_lexica",
"lemas": [
  "be [n]",
  "bes [n]"
]
```

Los campos lado y problema funcionan igual que en el caso descrito anteriormente, para identificar el problema y de qué lado se da.
El campo “categoria” identifica la categoría gramatical de la entrada.

En el campo “lemas” se identifican los diferentes lemas que pueden crear esta ambigüedad, así como la categoría gramatical asociada a cada uno. En caso de ser de diferentes categorías, este problema se puede solucionar mediante PoS. En caso contrario, se deberá hacer uso de un modelo de lenguaje para desambiguar.

conjugaciones_nuevo.json

Este archivo contiene, a priori, todos los verbos de apertium con sus conjugaciones que difieren entre catalán y valenciano. Tratar ambigüedades resulta fácil, dado que solo se dan cuando traducimos del valenciano al catalán. Todas aquellas formas que pueden presentar ambigüedad tienen un campo “problematica” en “true”. Para desambiguar, podría recurrirse a un LLM o en su defecto, comprobar si se puede resolver la ambigüedad mediante PoS.

verbos_diferentes_conjugados.json

Este probablemente el archivo más sencillo que tratar. Contiene todos aquellos verbos que son diferentes en forma en catalán y valenciano, así como todas las conjugaciones posibles que pueden presentar. De nuevo, las ambigüedades solo se pueden dar a la hora de traducir del valenciano al catalán. La forma de desambiguar sería la misma que en el caso anterior.

Resumen

- lexico_general.json:
    - Caso colisión-> Mirar forma canónica y usar esa
    - Caso homonimia->Si se puede, PoS, si no, LLM
- verbos (en general):
    - Solo ambigüedades al traducir de valenciano a catalán
    - Si spaCy saca el tiempo, modo y persona, PoS, si no, LLM